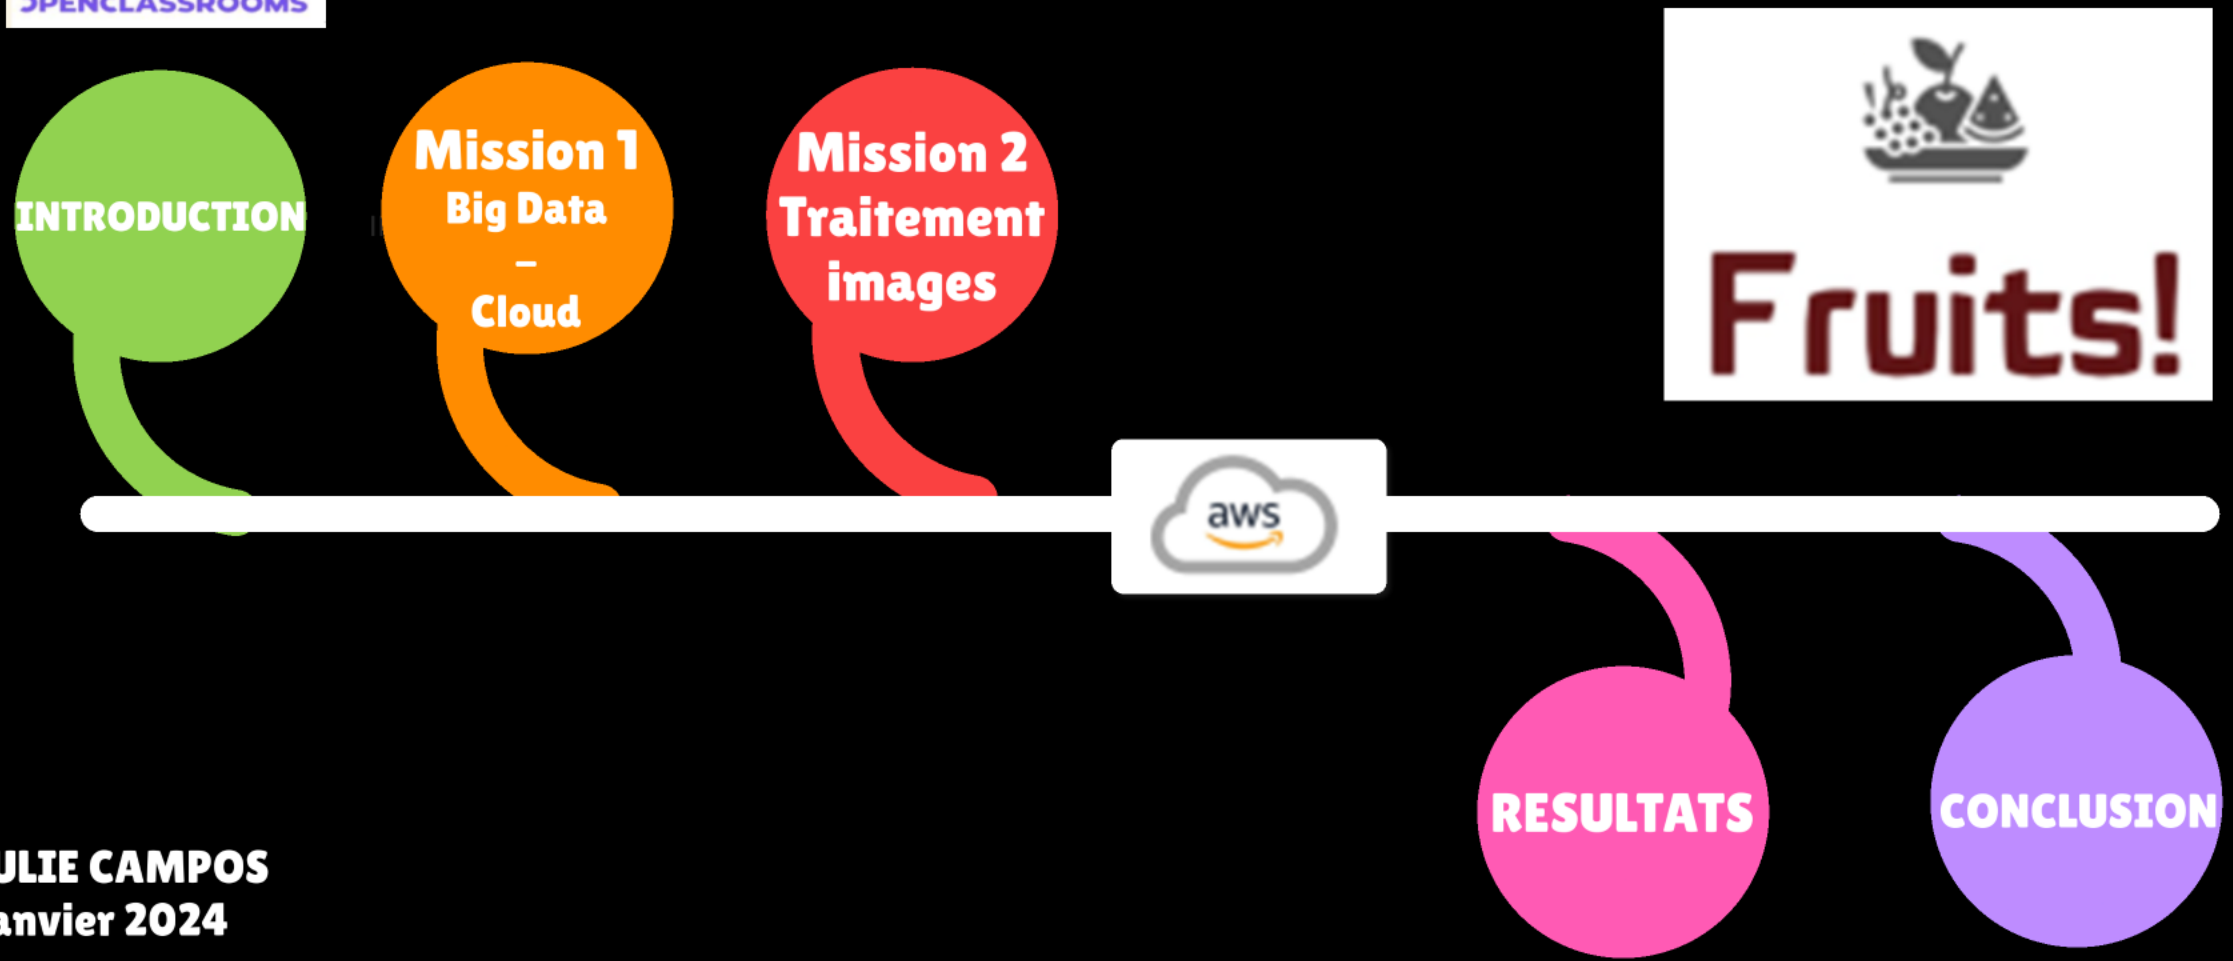
Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

INTRODUCTION



CONTEXTE

MISSIONS

CHOIX

METHODE

CONTEXTE

- **“Fruits ! ” :** jeune start-up de l’AgriTech qui cherche à proposer des **solutions innovantes pour la récolte de fruits**.
- **Son ambition : développer des robots cueilleurs intelligents** qui permettraient des traitements spécifiques pour chaque espèce de fruits
- **“Fruits ! ”** souhaite créer une **application grand public** qui permettrait de prendre en **photo un fruit et d'obtenir des informations sur ce fruit**.



Fruits!

OBJECTIF

Développement d’un moteur de classification de fruits

↓

Prototype architecture Big Data

MISSIONS

1. **Mettre en place l'architecture Big Data**
   nécessaire pour le passage à l'échelle
   en termes de volume de données.

2. **S'approprier la chaîne de traitement d'images:**
   - preprocessing
   - construction du modèle d'extraction des caractéristiques (transfert learning)
   - réduction de dimensions (ACP)

Choix techniques

Big Data

Calcul distribué



Pourquoi un environnement Big data ?

Big Data (ou données massives) : données telles que les solutions classiques de stockage, de gestion et de traitement ne suffisent plus.

Les 3V du Big Data

Volume	Le **Volume** des données générées nécessite de repenser la manière dont elles sont stockées.	• Avec une croissance rapide de l'application, le volume de données collectées augmentera considérablement. • Le Big Data permet de stocker, gérer et analyser ces grandes quantités de données de manière évolutive.
Vélocité	La **Vélocité** à laquelle nous parviennent ces données implique de mettre en place des solutions de traitement en temps réel qui ne paralysent pas le reste de l'application.	• Le nombre d'utilisateurs et de photos prises augmentera rapidement, générant une quantité importante de données en temps réel. • Le Big Data offre les outils nécessaires pour traiter et analyser ces données à grande vitesse.
Variété	Les données se présentent sous une grande **Variété** de formats : structurées (doc JSON), semi structurés (fichiers de log), non structurées (textes, images)...	• L'application mobile générera différents types de données, tels que des images de fruits, des informations associées et des métadonnées. • Le Big Data permet de traiter et d'analyser efficacement ces multiples sources de données hétérogènes.

SPARK

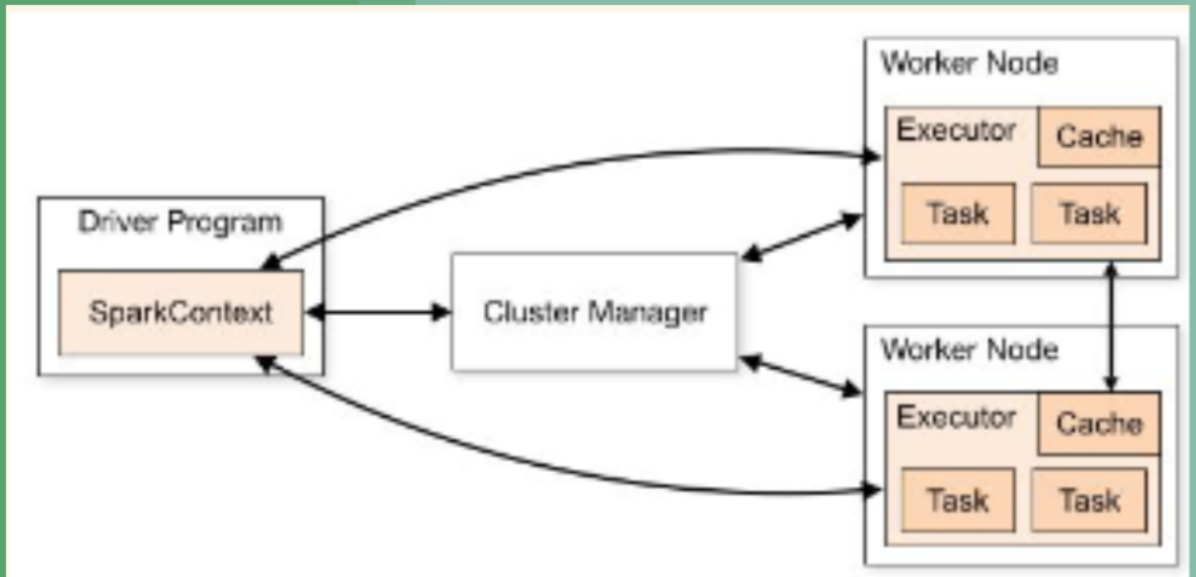
Calculs distribués :
distribution du stockage et des traitement des données sur plusieurs unités de calcul réparties en clusters afin de diviser le temps d'exécution d'une requête **(DIVISER POUR REGNER).**

Apach Spark :
Description

- framework open-source de calcul distribué

Avantages

- Données stockées en RAM (10 à 100x plus rapide qu'Hadoop)
- Outil qui permet de gérer et de coordonner l'exécution de tâches à travers un groupe d'ordinateurs (noeud)



Application Spark
Le **driver** distribue et planifie les tâches entre les différents **exécuteurs** qui les exécutent et permettent un traitement réparti. Il est le responsable de l'exécution du code sur les différentes machines.
Cluster Manager : assure le suivi des ressources disponibles.

METHODE

Environnement

- **Local:**
  - **OS:** linux -> Ubuntu 22.04 LTS ("The Jammy Jellyfish")
  - **vscode** -> 1.85.2

- **Distance (AWS, EMR):**
  - **EMR** 6.7.0
  - **Spark** 3.2.1
  - **Hadoop** 3.2.1
  - **JupyterHub** 1.4.1
  - **TensorFlow** 2.4.1

- **Librairies PySpark**
  - MLlib
  - boto3
  - numpy
  - pandas 1.2.5
  - s3fs
  - fsspec
  - Pilow (PiL)



















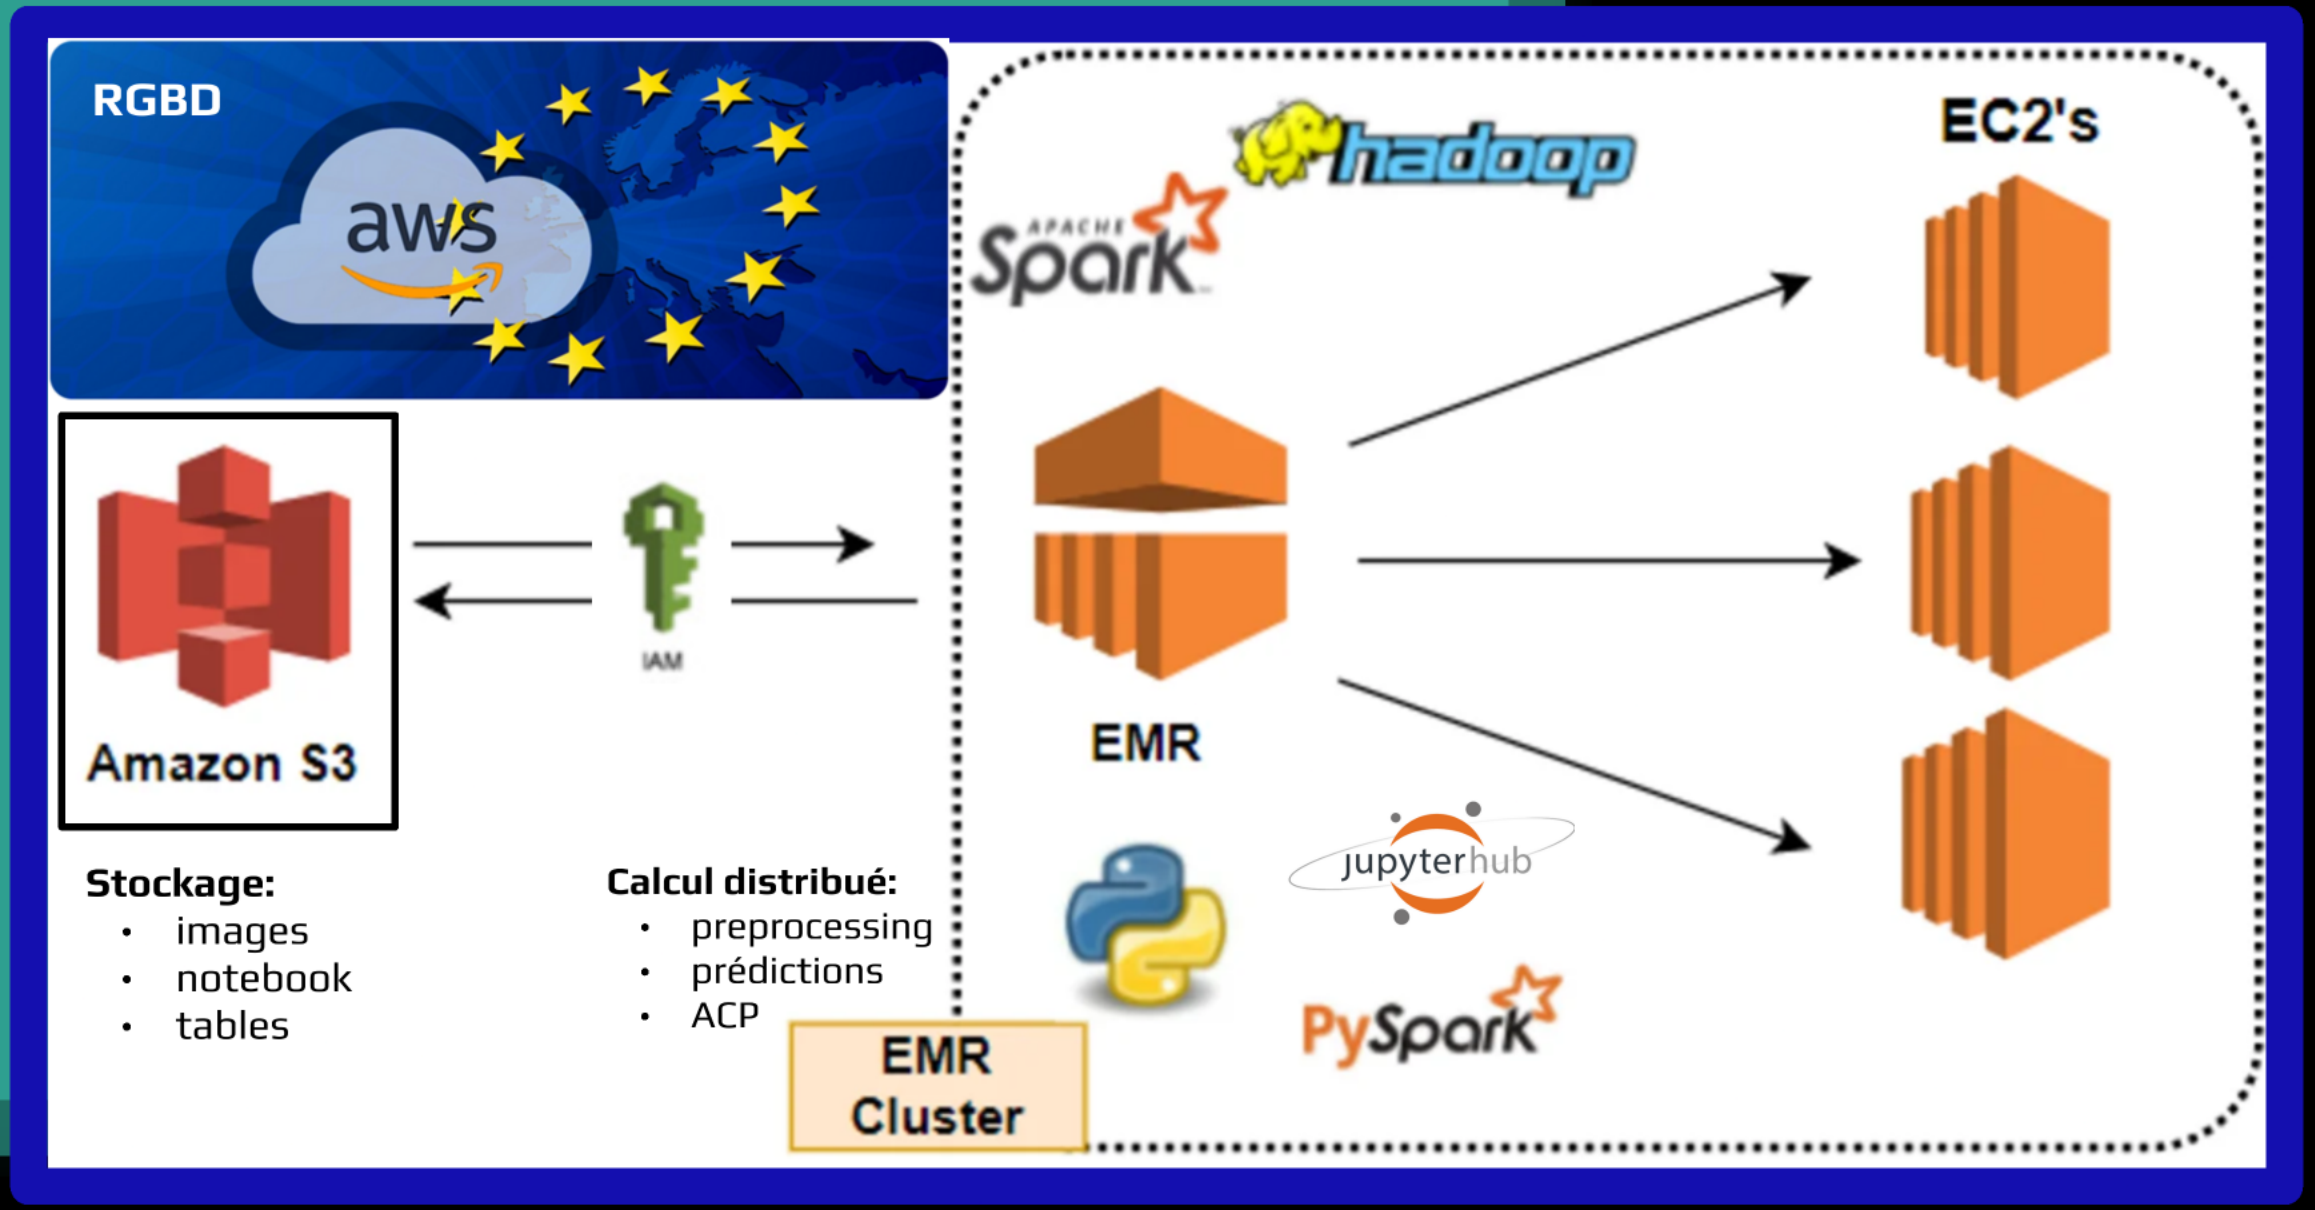


TensorFlow

MISSION 1

MISSION 2

ARCHITECTURE DATA



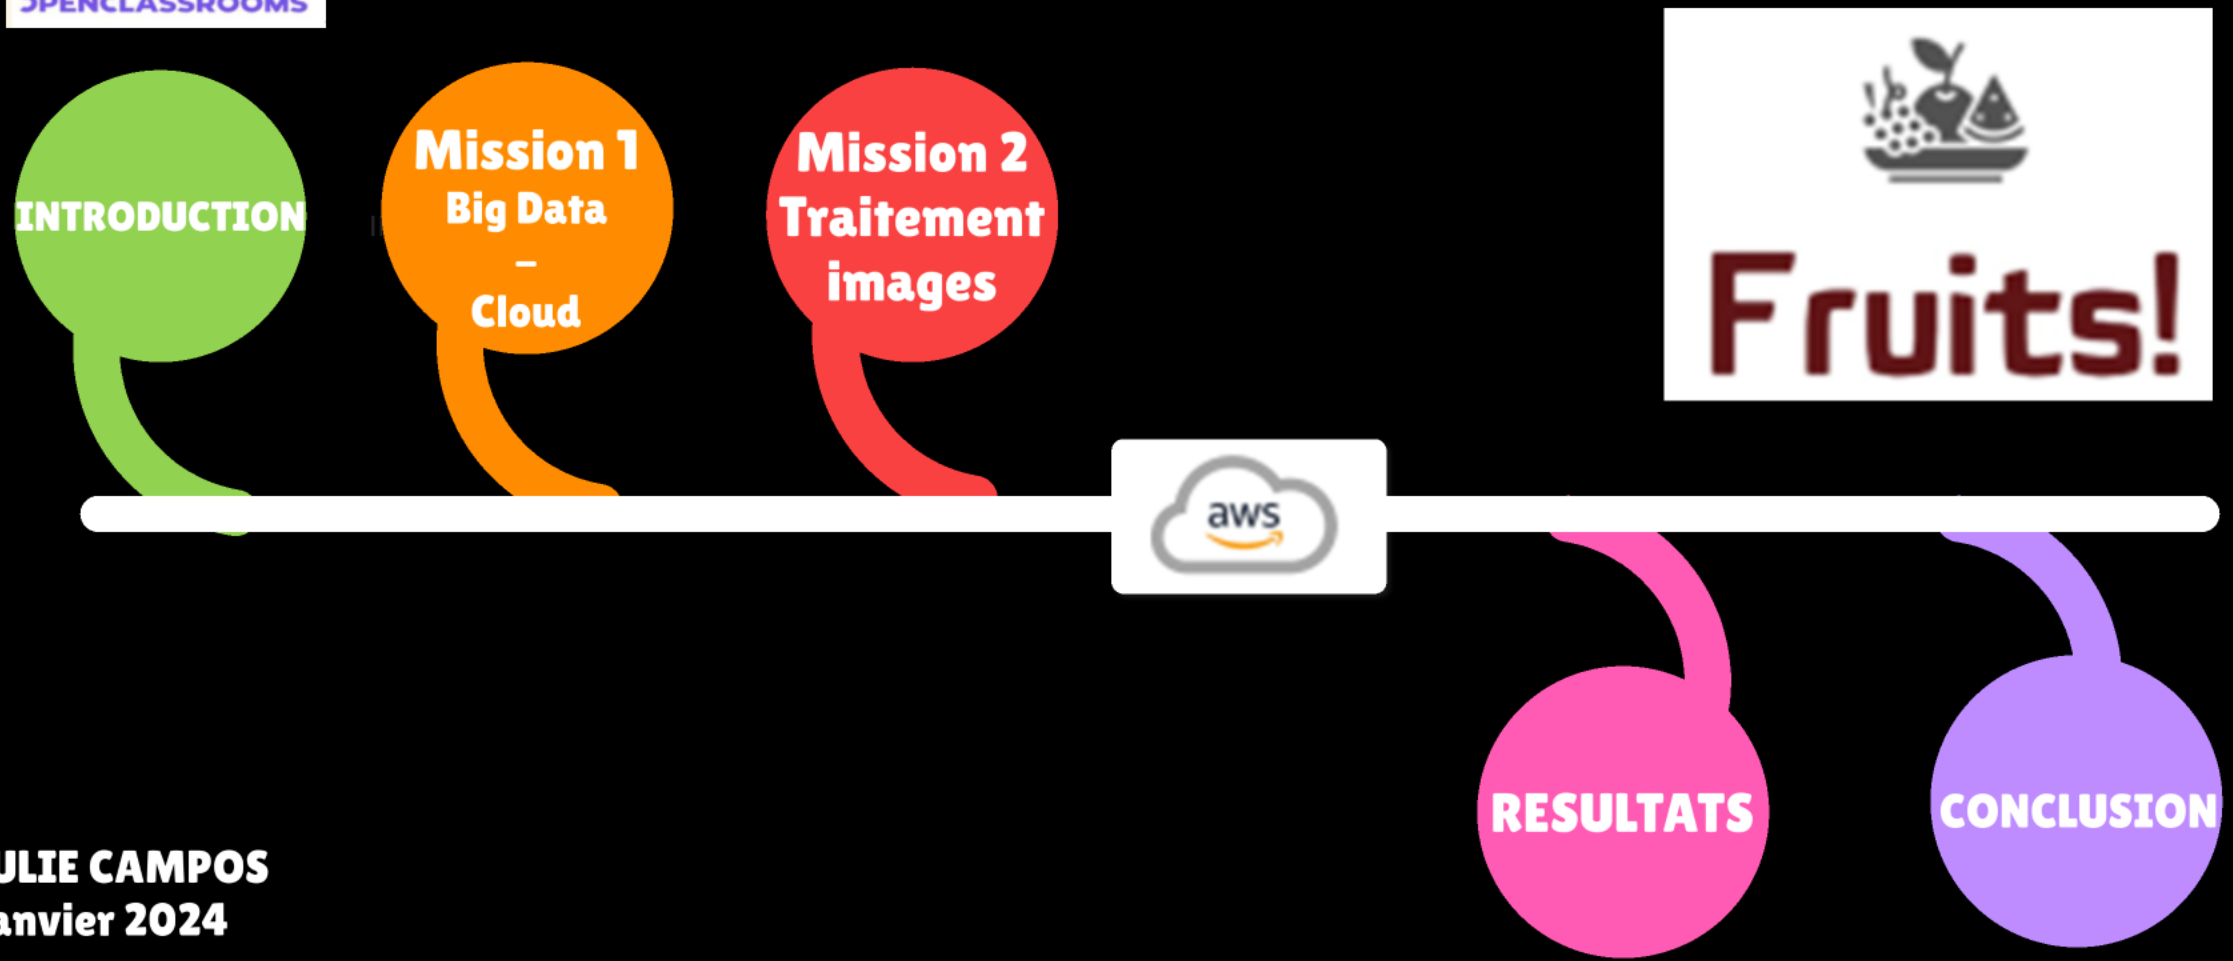
TRAITEMENT DES IMAGES

Chargement des données	Preprocessing	Extraction de features	Réduction de dimensions	Stockage des résultats
■ Images stockées dans un compartiment S3. ■ Chargement des images dans des Spark DataFrame.	■ Utilisation librairie PIL compartiment S3. ■ Redimensionnement des images (100,100,3) ⇒ (224, 224, 3)	■ Modèle MobileNetV2, pré-entrainé sur la base ImageNet (transfert Learning): dont la dernière couche (classification) a été retirée, et les poids ont été initialisés avec des poids pré-entraînés	■ Utilisation librairie MLlib ■ Normalisation (StandarScaler) ■ ACP (>90% variance expliquée)	■ Écriture des résultats dans des fichiers Parquet. ■ Stockage dans le compartiment S3.

Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

Mission 1

Déploiement de la solution dans le CLOUD

1/ Choix Technique :

- Prestataire
- Solution de Stockage (S3)
- serveur de calcul distritbué (EMR)
  PAAS: Plateforme As A Service

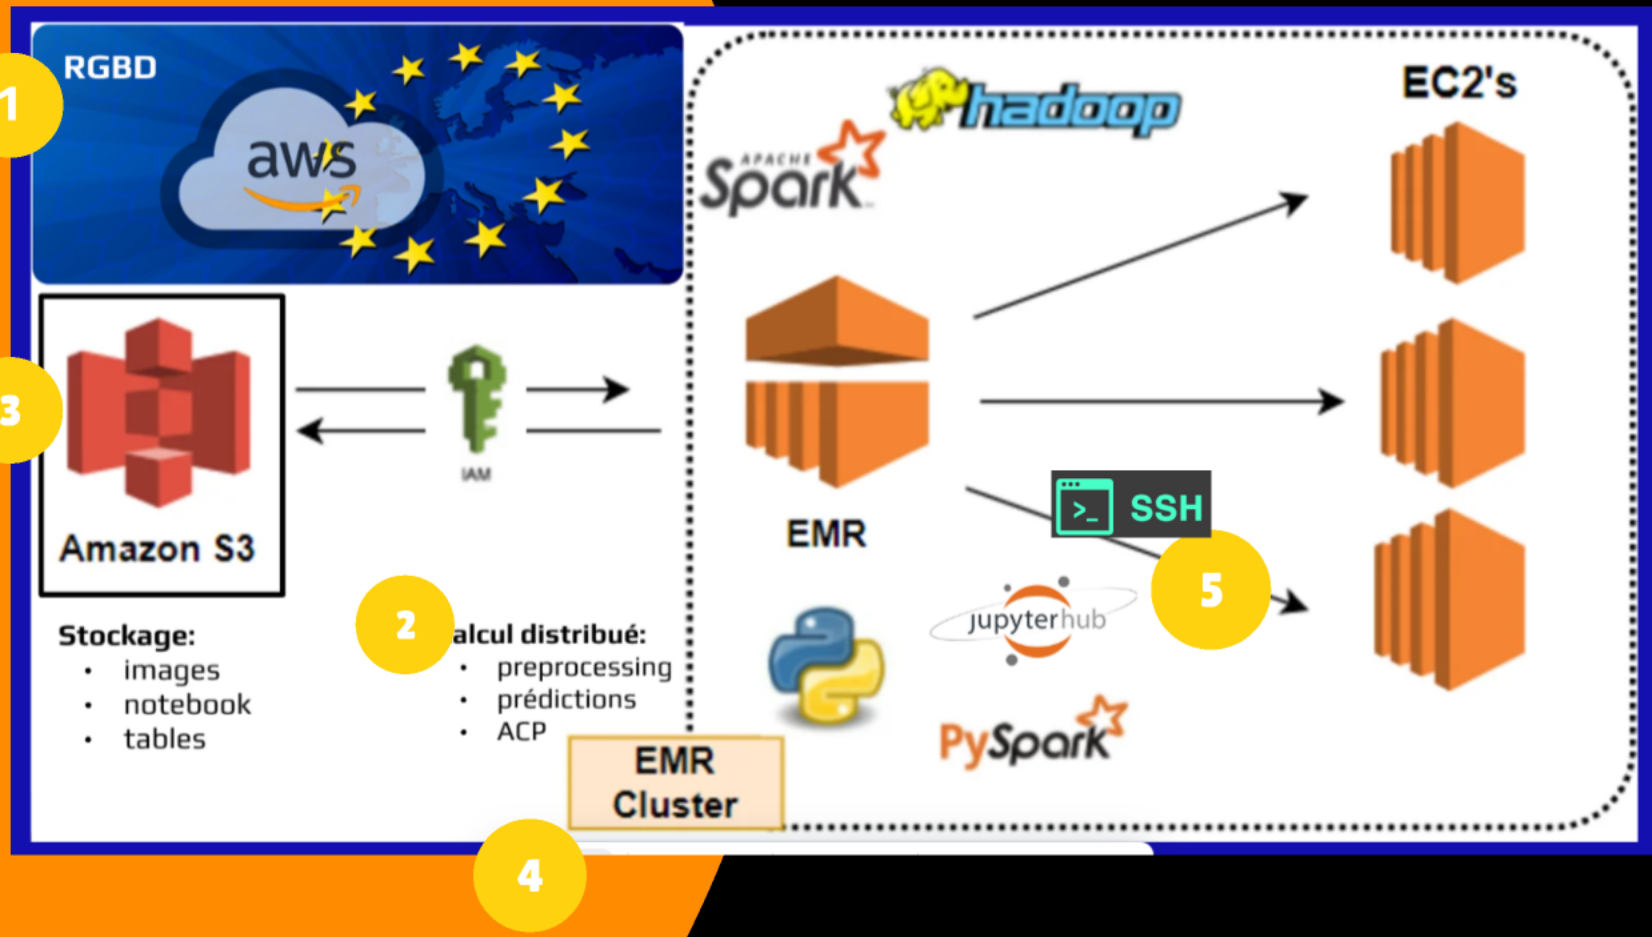
2/ Configuration de l'environnement de travail

- Interface AWS (AWS Cli)
- Service IAM (clef d'accès)

3/ Chargement des données sur S3

4/ Configuration du serveur EMR

- 4.1 - Logiciel
- 4.2 - Matériel
- 4.3 - Cluster:
  - Options générales
  - Option: action d'amorcage
- 4.4 - Sécurité de connection
  - Création clef EC2



5/ Création du tunnel SSH à l'instance EC2 (Maître)

- 5.1 - vers le driver: connexion entrante (port 22)
- 5.2 - connection sortante (port 5555)
- 5.3 - Accès à JupiterHub (configuration navigateur tunnel shh : FoxyProxy, port 5555)

2. Service IAM (Identity and Access Management)

ROLE

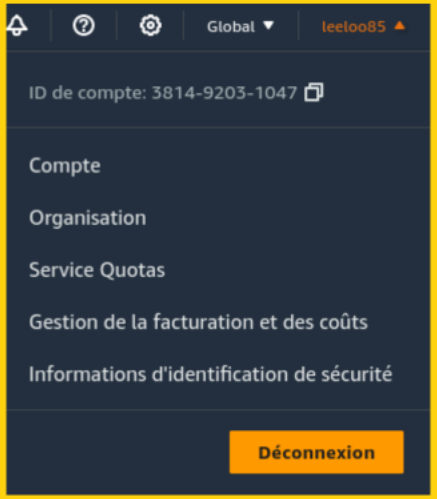
Gestion des droits utilisateurs (accès aux données S3)
Régulation des autorisations/sécurité

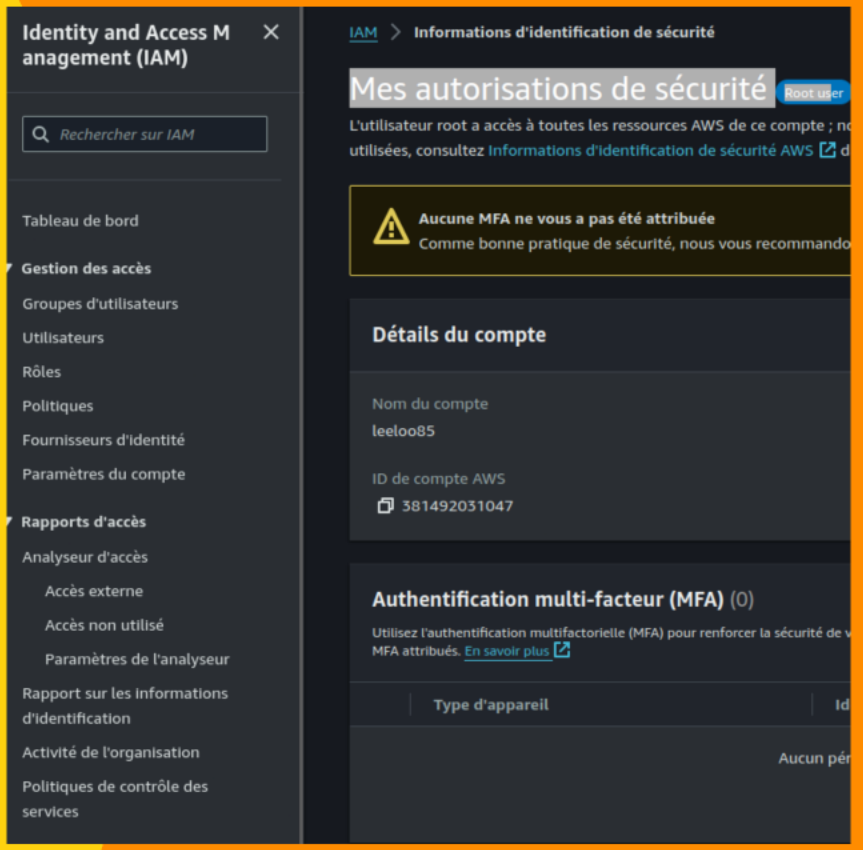
PROTOCOL

1/ Création d'un compte AWS
2/ Onglet untilisateur > Informations d'identification de sécurité (IAM)

3/ Création d'une paire de clés d'accès (Root)

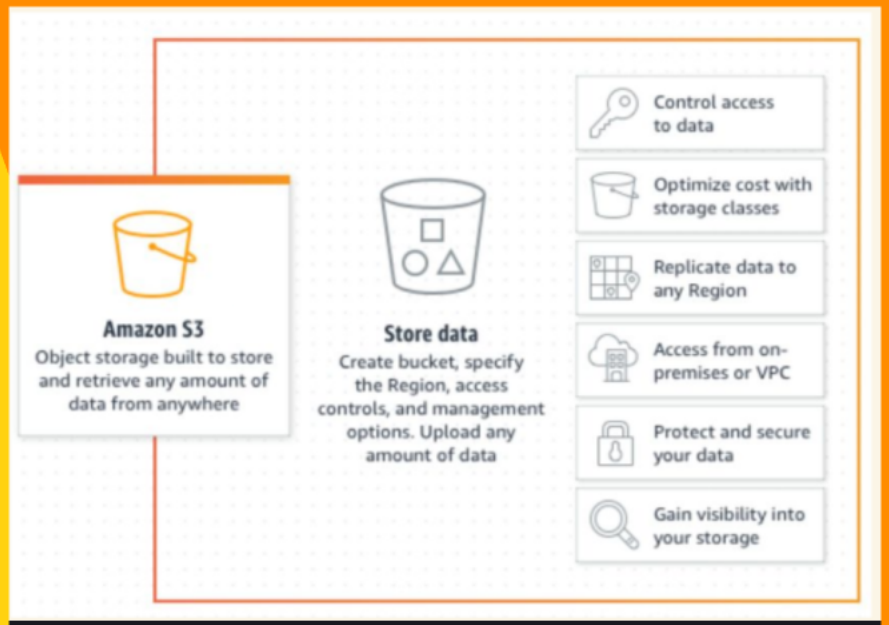
-> Pourquoi ?
CONNECTION AUTOMATIQUE, sans demander systématiquement login/mot de passe via le terminal (autorisation connection
-> Mise en oeuvre
Onglet : Informations d'identification de sécurité >Créer une clé d'accès







Solution de stockage des données sur S3

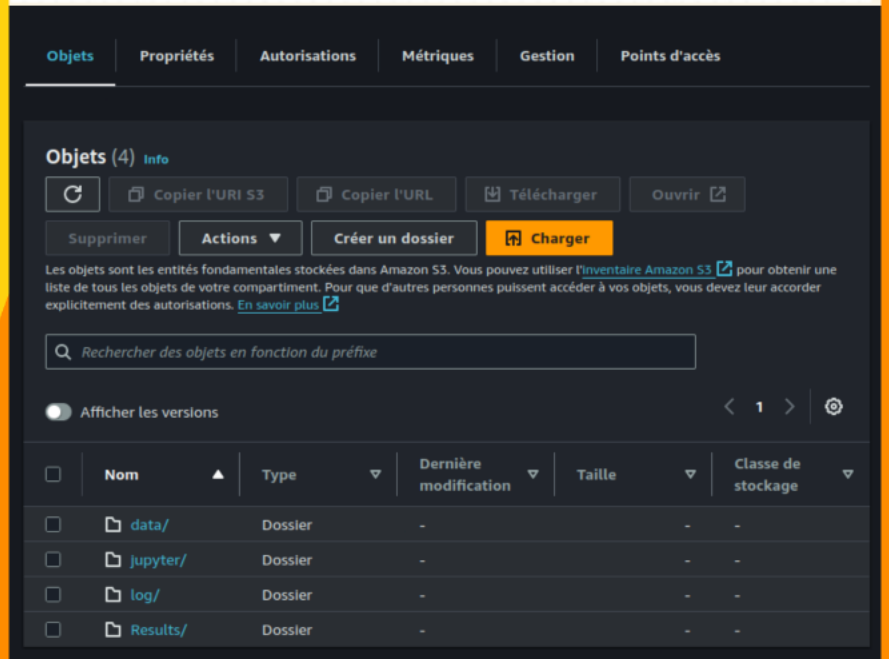


Description S3 (Simple Storage Service) :

- Stockage d'une grande variété d'objets (fichiers, image, vidéos...)
- Évolutivité avec espace disponible illimité.
- Indépendant des serveurs EC2.
- Accès aux données très rapide.
- Possibilité de définir des politiques d'accès IAM pour contrôler les autorisations d'accès aux buckets et aux objets.
- Chiffrement côté serveur pour sécuriser les données stockées dans S3.
- Classes de stockage (options) adaptées à l'utilisation.

Mise en Oeuvre:

- Création d'un compartiment ("bucket") **: oc-p8-part4**
  aws s3 mb s3://oc-p8-part4)
  - Choisir la même région pour les serveurs EC2 et S3: **Irlande (EU)** -> RGBG
- Chargement des données sur le bucket S3 :
  - Fichier de configuration avec amorçage: **data/bootstrap-emr.sh**
    aws s3 cp bootstrap-emr.sh s3://oc-p8-part4/data/bootstrap-emr.sh
  - Répertoire des images Test: **data/Test**
    aws s3 sync . s3://oc-p8-part4/data/Test
  - Notebook: **jupyter**
    aws s3 cp p8.ipynb s3://oc-p8-part4/jupyter/jovyan/
- Écriture des résultats: **Results.**



Création d'un cluster de calculs distribués avec EMR



Elastic MapReduce (EMR), solution PAAS :

- plateforme permettant d'exécuter des traitements de données distribuées à grande échelle, en utilisant des frameworks tels que Hadoop et Spark.

- utilise des instances EC2 (Elastic compute cloud, serveur) avec des applications préinstallées et configurées pour créer et gérer le cluster de calculs distribués.

- **Avantages :** évolutivité, flexibilité, gestion simplifiée.

4.1 Configuration Logiciel

4.2 Configuration matériel

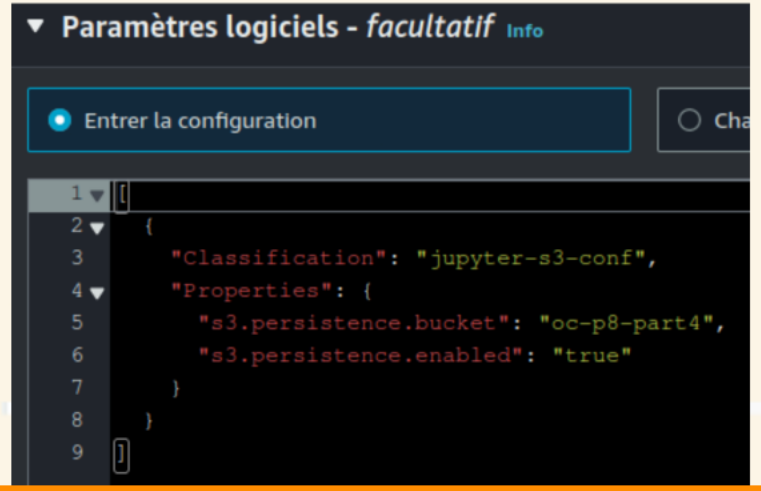
4.3 Configuration Cluster

4.4 Configuration Sécurité

EMR / 1 – Configuration Logiciel

- **Choix des logiciels :**
  - Hadoop et Spark : calculs distribués.
  - TensorFlow : import du modèle et transfert learning.
  - JupyterHub : exécution des scripts Pyspark du Notebook.

- **Paramétrage de la persistance** des notebooks créés et ouverts via JupyterHub (configuration au format JSON).

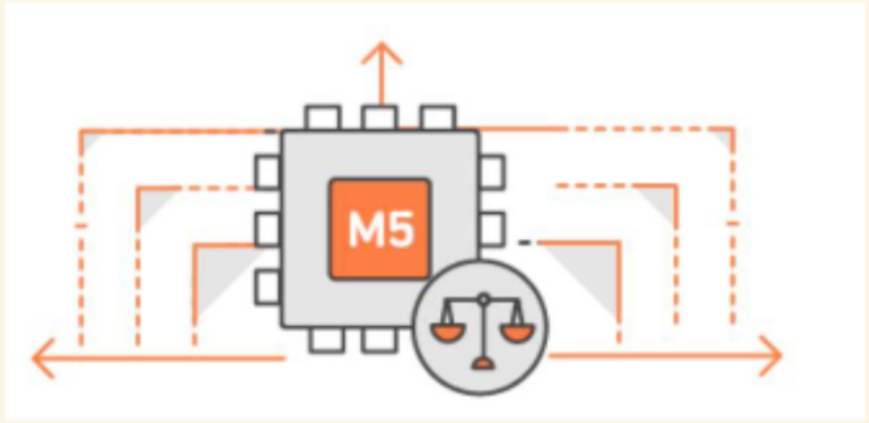




EMR / 2 – Configuration Matériel

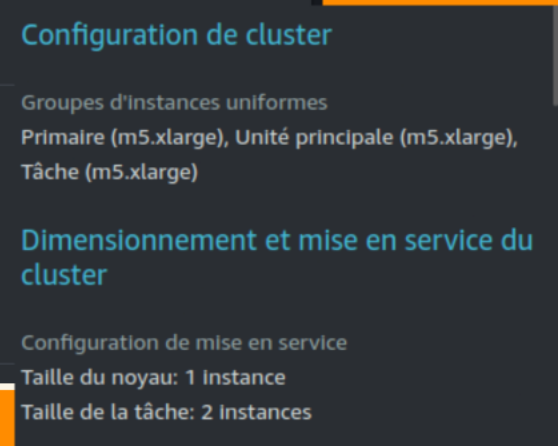
Configuration Matériel (choix des instances) :

- 1 instance **Maître** (driver), 2 instances **principales** (workers)
- Instances de **type M5** (instances de type équilibrées), et **xlarge** (la moins onéreuse disponible).



vCPU : 4 / Mémoire (Gio) : 16
Bande passante réseau (Gbit/s) : jusqu'10
Bande passante EBS (Mbit/s) : Jusqu'à 4 750

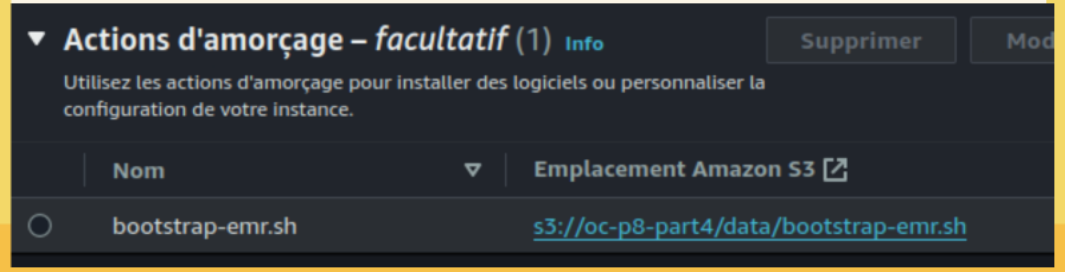




EMR / 3- Configuration du cluster

Actions d'amorçage ou bootstrapping

- Choix des **packages manquants à installer**, utiles pour l'exécution du notebook.
- **A l'initialisation du serveur**, afin que les packages soient installés sur l'ensemble des machines du cluster et non pas uniquement sur le driver.
- Création du fichier **"bootstrap-emr.sh"** contenant commandes "**pip install**"pour installer les bibliothèques manquantes, et chargement sur le compartiment S3 (racine).
- Ajout du script dans les **actions d'amorçage**.




```
#!/bin/bash
sudo python3 -m pip install -U setuptools
sudo python3 -m pip install -U pip
sudo python3 -m pip install whell
sudo python3 -m pip install pillow
sudo python3 -m pip install pandas==1.2.5
sudo python3 -m pip install pyarrow
sudo python3 -m pip install boto3
sudo python3 -m pip install s3fs
sudo python3 -m pip install fsspec
```

EMR / 4 – Sécurité

Rôle Identity and Access Management (IAM) Info

Choisissez ou créez une fonction du service et un profil d'instance pour les instances EC2 de votre cluster.

Fonction du service Amazon EMR Info

La fonction du service est un rôle IAM assumé par Amazon EMR pour mettre en service des ressources et effectuer des actions au niveau du service avec d'autres services AWS.

- ○ Choisir une fonction du service existant
  Sélectionnez une fonction du service par défaut ou un rôle personnalisé avec des stratégies IAM attachées afin que votre cluster puisse interagir avec d'autres services AWS.
- ◉ Créez une fonction du service
  Laissez Amazon EMR créer une nouvelle fonction du service afin que vous puissiez accorder et restreindre l'accès aux ressources d'autres services AWS.

Profil d'instance EC2 pour Amazon EMR

Le profil d'instance attribue un rôle à chaque instance EC2 d'un cluster. Le profil d'instance doit spécifier un rôle qui peut accéder aux ressources pour vos étapes et actions d'amorçage.

- ○ Choisir un profil d'instance existant
  Sélectionnez un rôle par défaut ou un profil d'instance personnalisé avec des stratégies IAM attachées afin que votre cluster puisse interagir avec vos ressources dans Amazon S3.
- ◉ Choisir un profil d'instance
  Laissez Amazon EMR créer un profil d'instance afin de pouvoir spécifier un ensemble personnalisé de ressources auquel il peut accéder dans Amazon S3.

Accès au compartiment S3 Info

- ○ Compartiments S3 ou préfixes spécifiques de votre compte Info
  Choisissez les compartiments ou préfixes auxquels vous voulez que ce profil d'instance accède.
- ◉ Tous les compartiments S3 de ce compte avec accès en lecture et en écriture
  Accordez au profil d'instance l'accès à tous les compartiments pour lesquels l'accès en lecture et en écriture est activé dans votre compte.

Création paire clef EC2 onglet EC2:

- ▼ Réseau et sécurité
  - Groupes de sécurité
  - Adresses IP élastiques
  - Groupes de placement
  - Paires de clés
  - Interfaces réseau

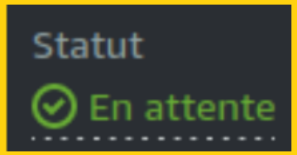
Paires de clés (1) Informations

Rechercher Key Pair par attribut ou identification

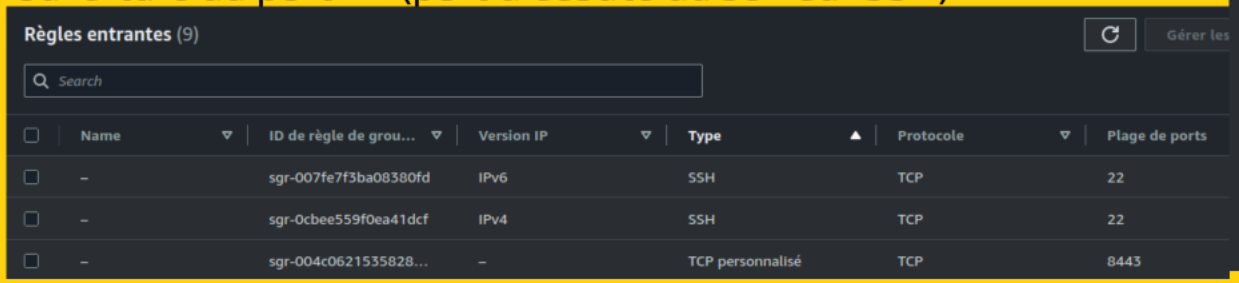
Nom	Type
leeloo-ec2	rsa

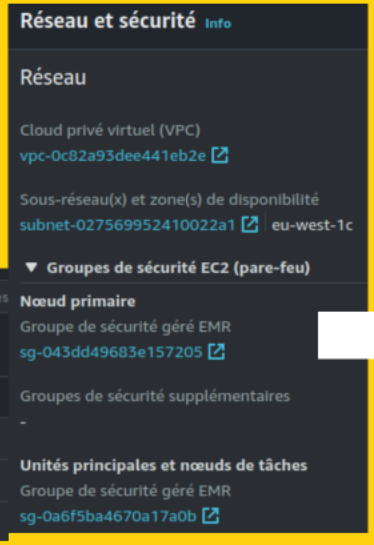
SSH 5/ Création d'un tunnel SSH à l'instance EC2

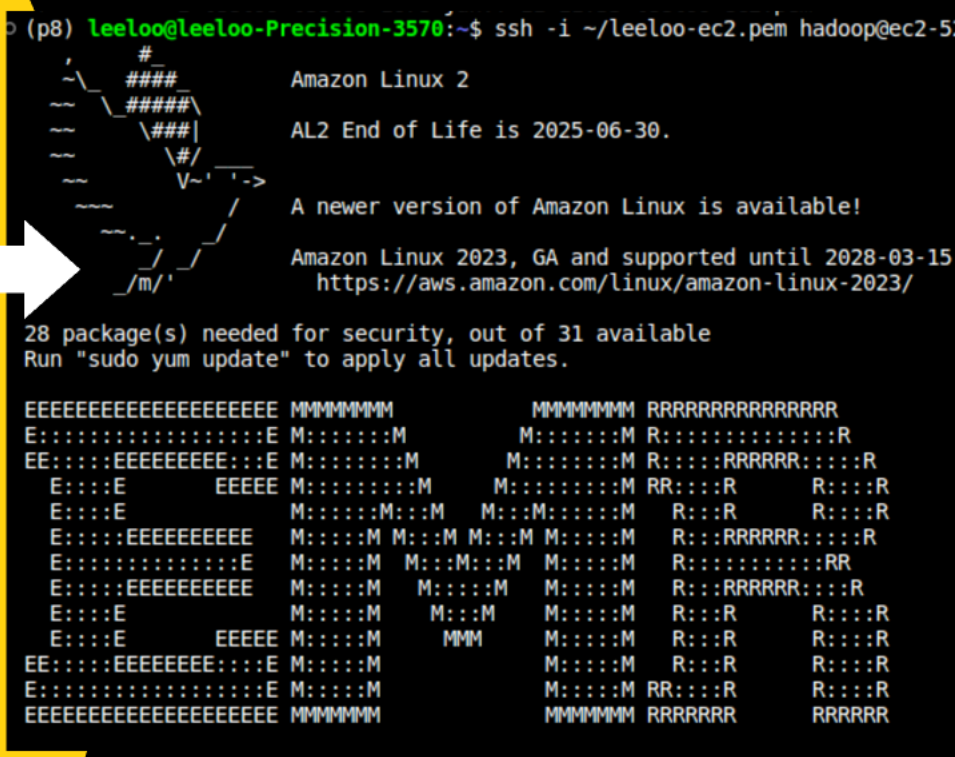
Quand cluster EMR lancé



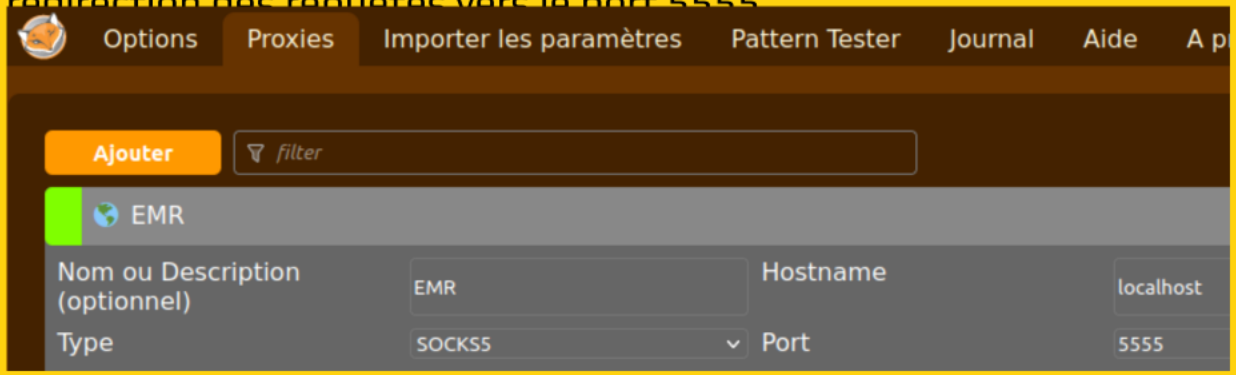
1/ Modification du groupe de sécurité EC2 du driver :
Autorisation connexions entrantes du driver :
ouverture du port 22 (port d'écoute du serveur SSH).



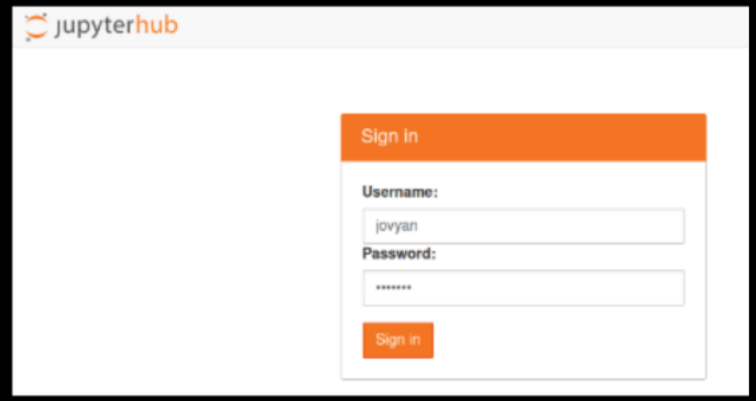




2/ Création du tunnel SSH vers le driver avec FoxyProxy:
redirection des requêtes vers le port 5555



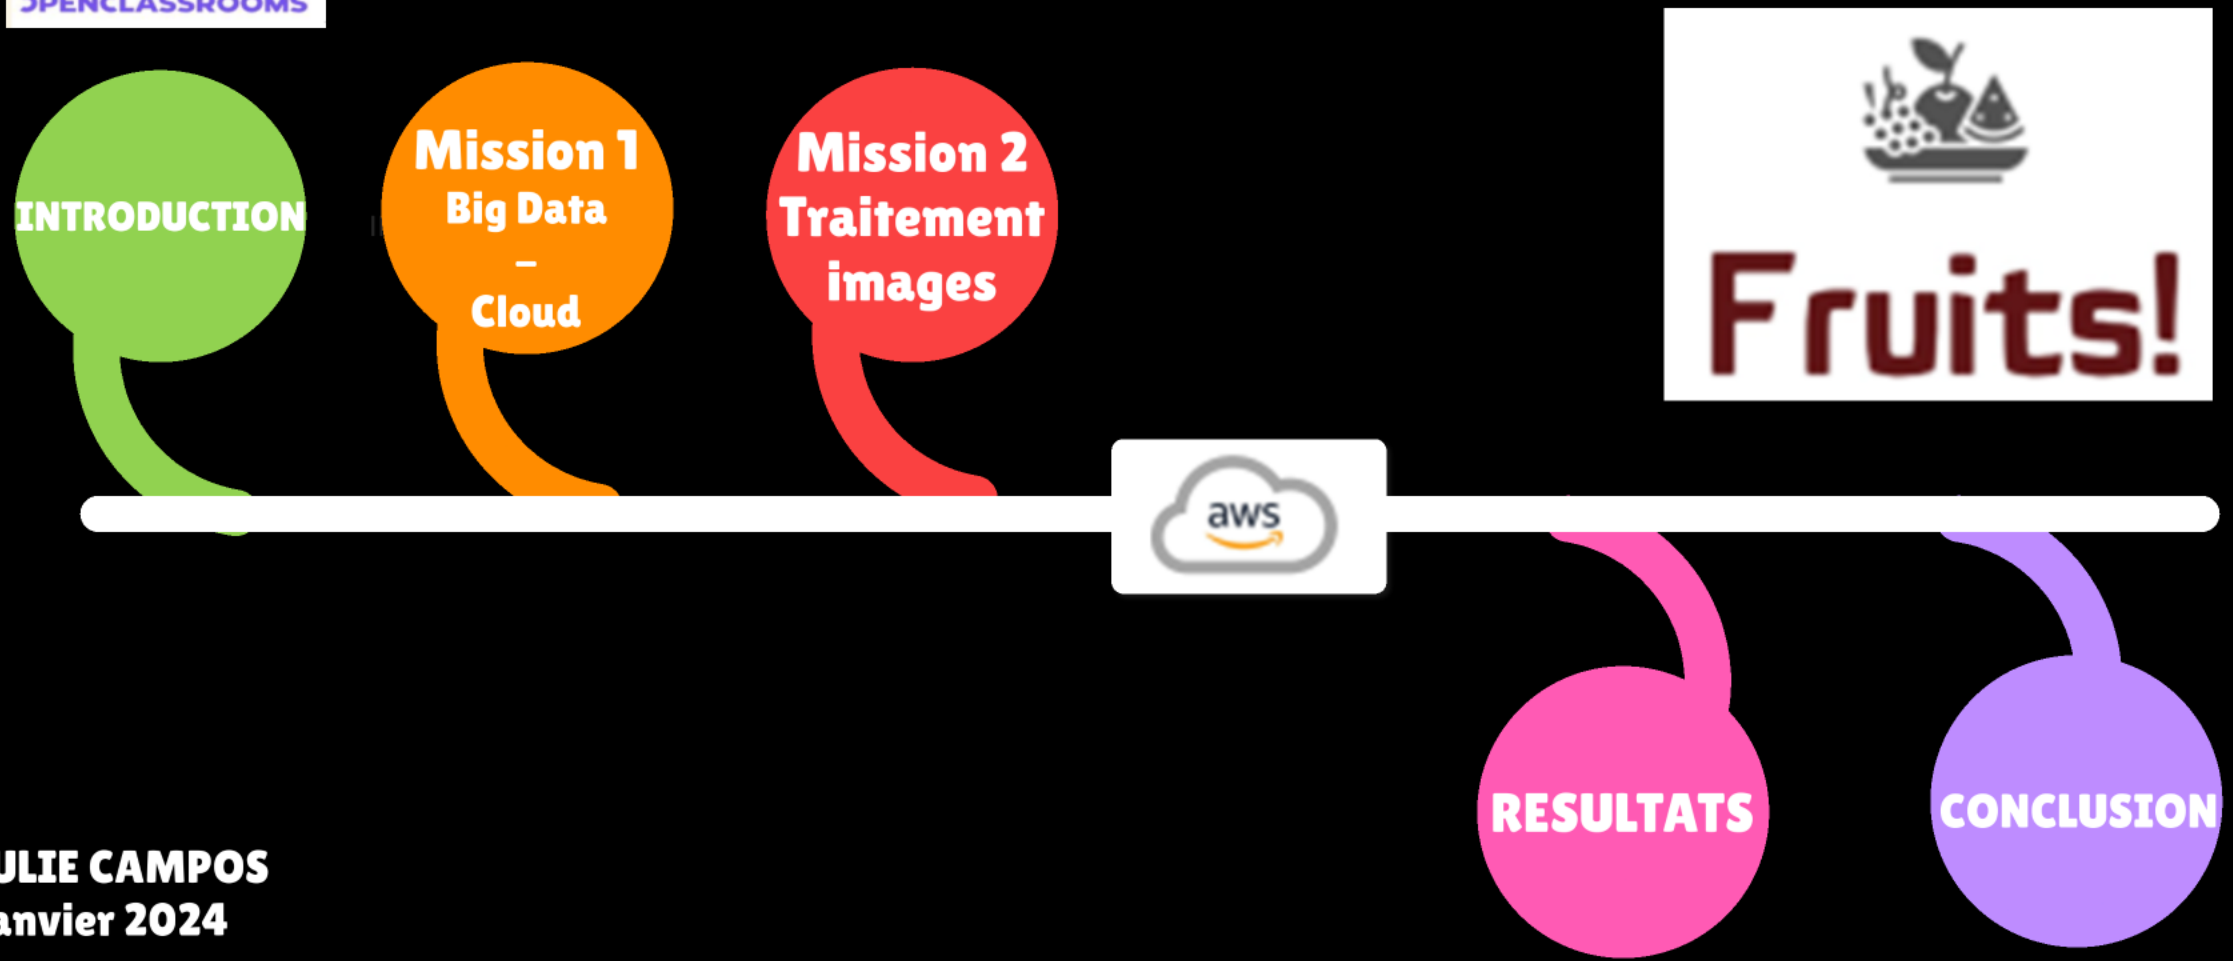




Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

MISSION 2
Traitement des images

Présentation des données

Chargement des données	Preprocessing	Extraction de features	Réduction de dimensions	Stockage des résultats
▪ Images stockées dans un compartiment S3. ▪ Chargement des images dans des Spark DataFrame.	▪ Utilisation librairie PIL compartiment S3. ▪ Redimensionnement des images (100,100,3) ⇒ (224, 224, 3)	▪ Modèle MobileNetV2, pré-entrainé sur la base ImageNet (transfert Learning): dont la dernière couche (classification) a été retirée, et les poids ont été initialisés avec des poids pré-entraînés	▪ Utilisation librairie MLlib ▪ Normalisation (StandarScaler) ▪ ACP (>90% variance expliquée)	▪ Écriture des résultats dans des fichiers Parquet. ▪ Stockage dans le compartiment S3.

MobilNetV2

Extraction de features

Présentation des données

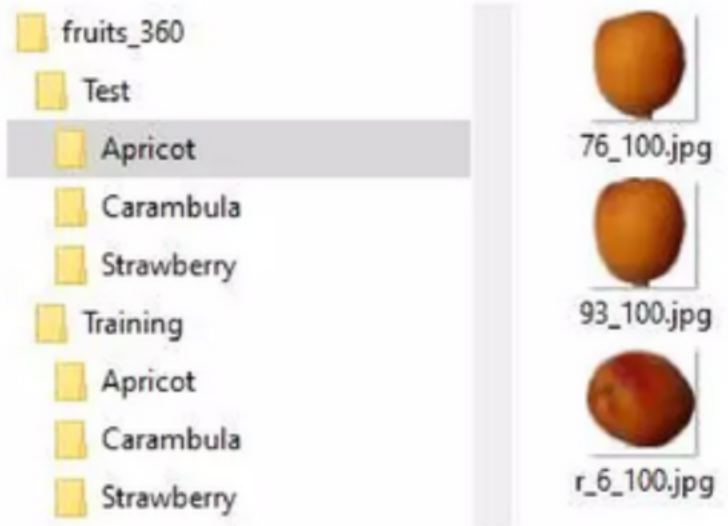
Images de fruits

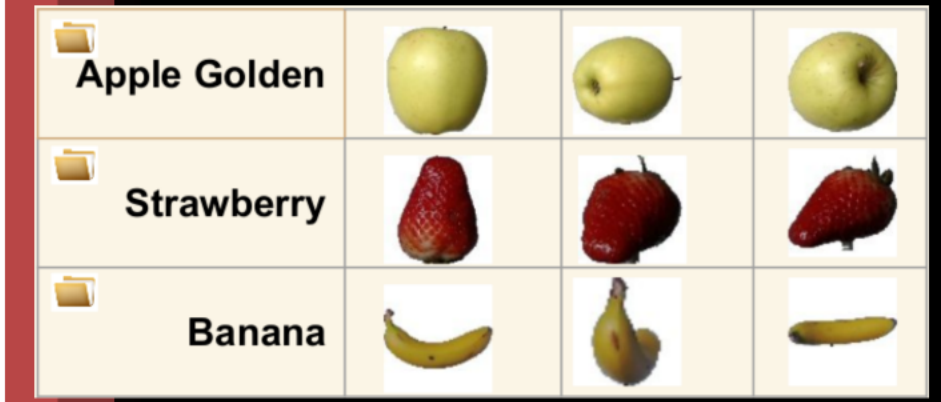
- Propriétés
  - Dimensions (pixels): 100 X 100
  - Profondeur: 24

Stockage

JEU DE TEST
131 répertoires (catégories)
22 688 images
152 Mo

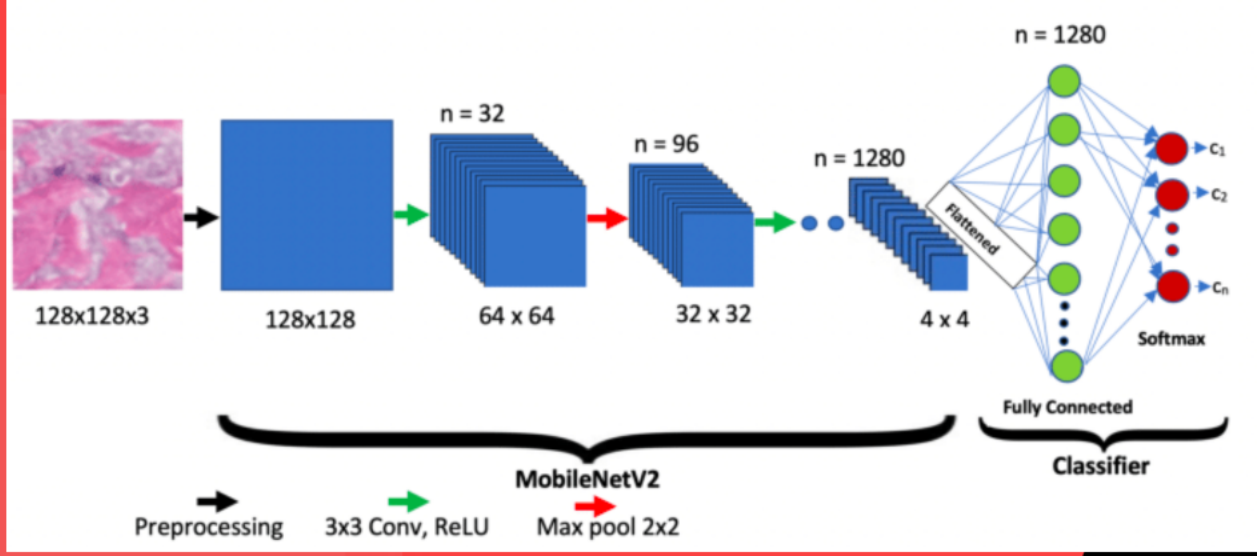
JEU D'ENTRAINEMENT
131 répertoires (catégories)
67 692 images
467 Mo





https://www.kaggle.com/datasets/moltean/fruits?select=fruits-360_dataset

MobileNetV2



Choix du modèle MobileNetV2 :

- Modèle de réseau de neurones convolutifs (CNN) pré-entraîné sur la base ImageNet
- **Spécialement conçu sur pour appareils mobiles** avec ressources limitées :
- Rapidité d'exécution (adapté pour le traitement d'un gros volume de données).
- Faible dimensionnalité du vecteur de sortie (1,1,1280).

Transfer Learning :

réation d'un nouveau modèle avec pour couche de sortie l'avant-dernière couche (extraction des features images) du modèle MobileNetV2 .

- Dimension vecteur de sortie (1, 1, 1280).
- Diffusion des poids avec sparkContext.broadcast() de PySpark :
  - Chargement du modèle sur le driver puis diffusion des poids aux workers.
  - Permet de distribuer une variable à travers le cluster afin qu'elle soit disponible pour tous les nœuds de calcul.

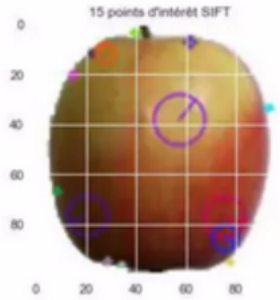
Variables explicatives

Points d'intérêts et descripteurs

Descripteurs

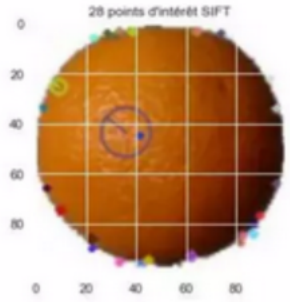
Points d'intérêt

image 0



...

image 241

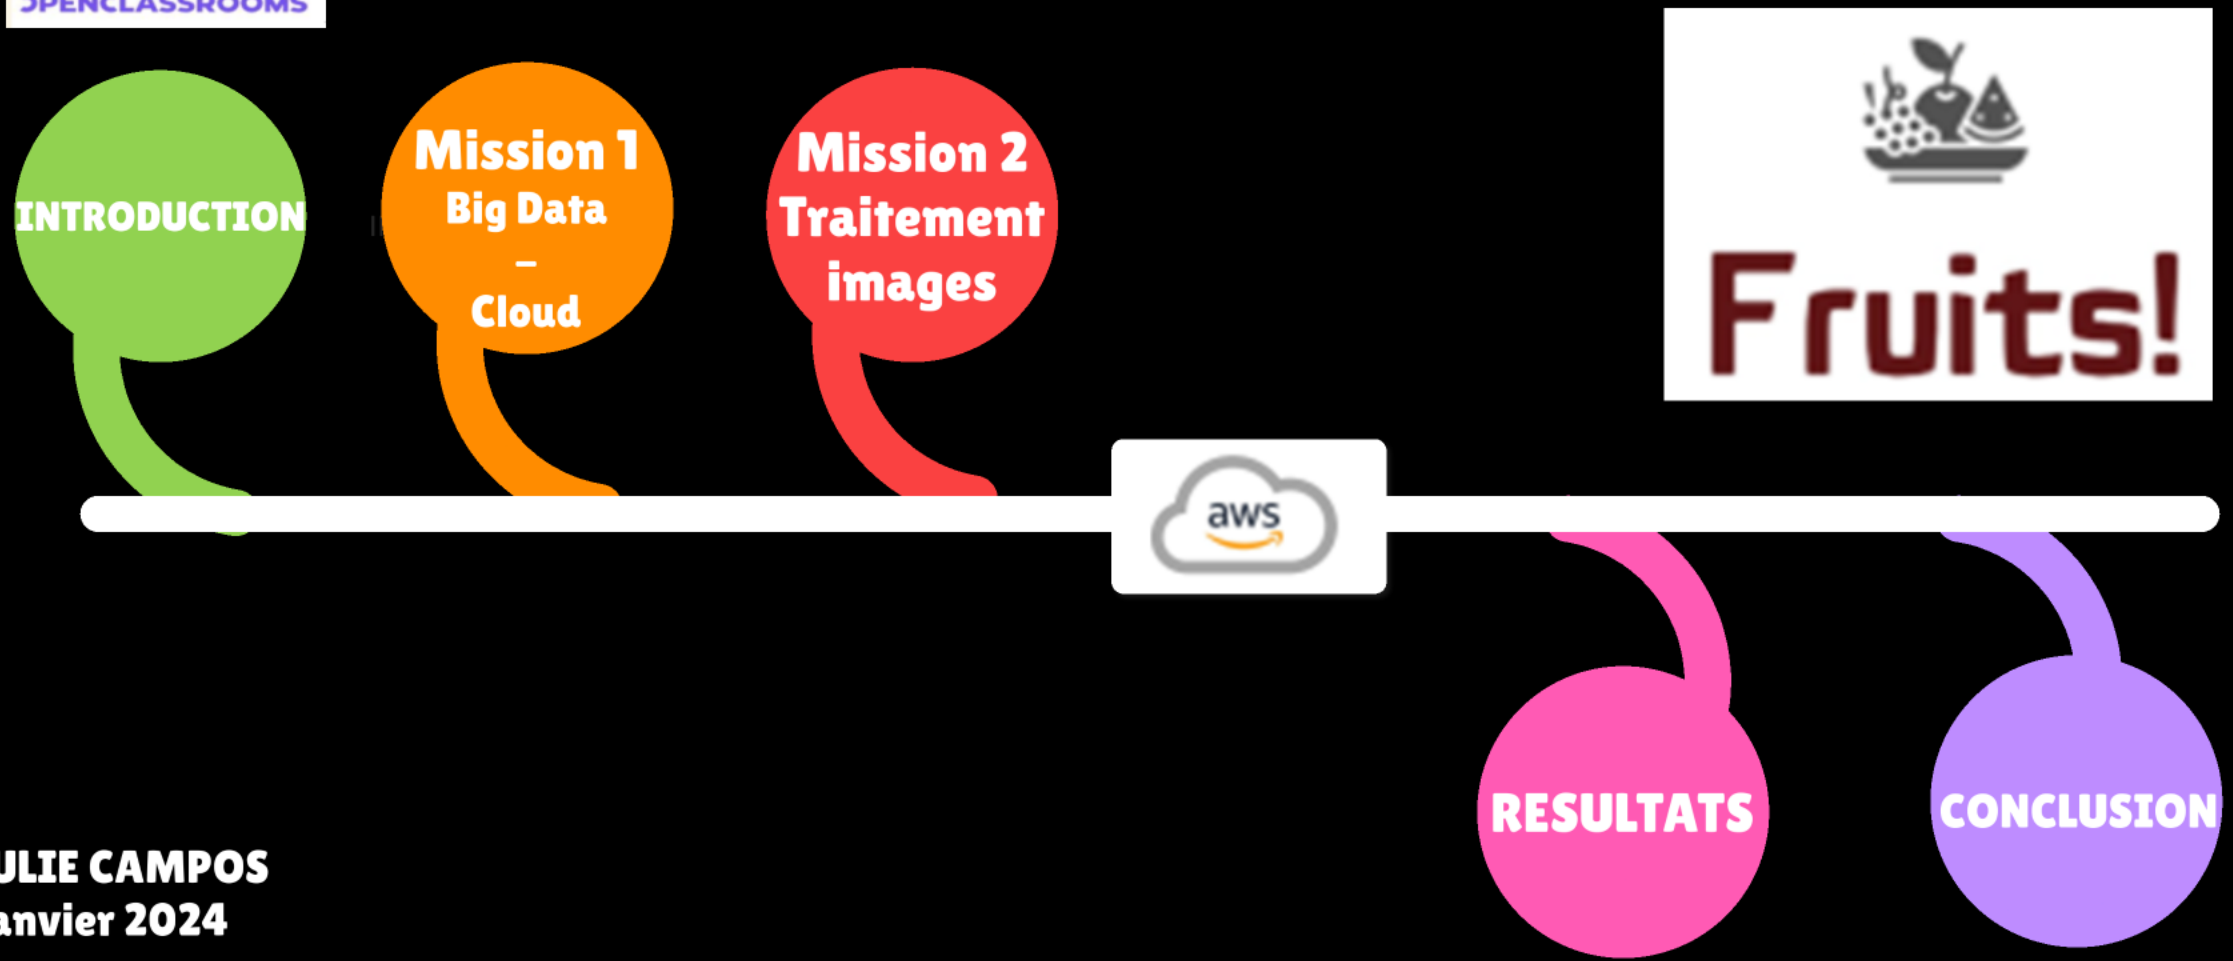


	0	1	2	3	4	5	6	7	8	9	...	119	120	121	122	123	124	125	126	127	128
0	0.0	6.0	0.0	0.0	0.0	0.0	0.0	1.0	7.0	163.0	...	0.0	35.0	23.0	1.0	0.0	0.0	0.0	0.0	0.0	2.0
1	0.0	6.0	0.0	0.0	0.0	0.0	2.0	8.0	9.0	173.0	...	0.0	84.0	16.0	0.0	0.0	0.0	0.0	0.0	0.0	4.0
2	0.0	0.0	0.0	2.0	110.0	27.0	10.0	0.0	0.0	13.0	...	9.0	103.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	1.0	18.0	14.0	167.0	...	0.0	79.0	17.0	1.0	1.0	0.0	0.0	0.0	0.0	3.0
4	0.0	21.0	31.0	0.0	0.0	0.0	5.0	58.0	12.0	150.0	...	14.0	27.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7135	241.0	7.0	1.0	0.0	0.0	3.0	1.0	0.0	1.0	172.0	...	0.0	30.0	21.0	2.0	0.0	0.0	0.0	0.0	1.0	2.0
7136	241.0	2.0	0.0	0.0	0.0	4.0	2.0	0.0	0.0	163.0	...	0.0	85.0	24.0	3.0	1.0	0.0	0.0	0.0	0.0	6.0
7137	241.0	64.0	12.0	0.0	3.0	4.0	0.0	0.0	0.0	195.0	...	0.0	19.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
7138	241.0	1.0	1.0	0.0	4.0	6.0	0.0	0.0	0.0	153.0	...	0.0	80.0	29.0	0.0	0.0	0.0	0.0	0.0	0.0	7.0
7139	241.0	1.0	1.0	0.0	10.0	10.0	0.0	0.0	0.0	174.0	...	0.0	20.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

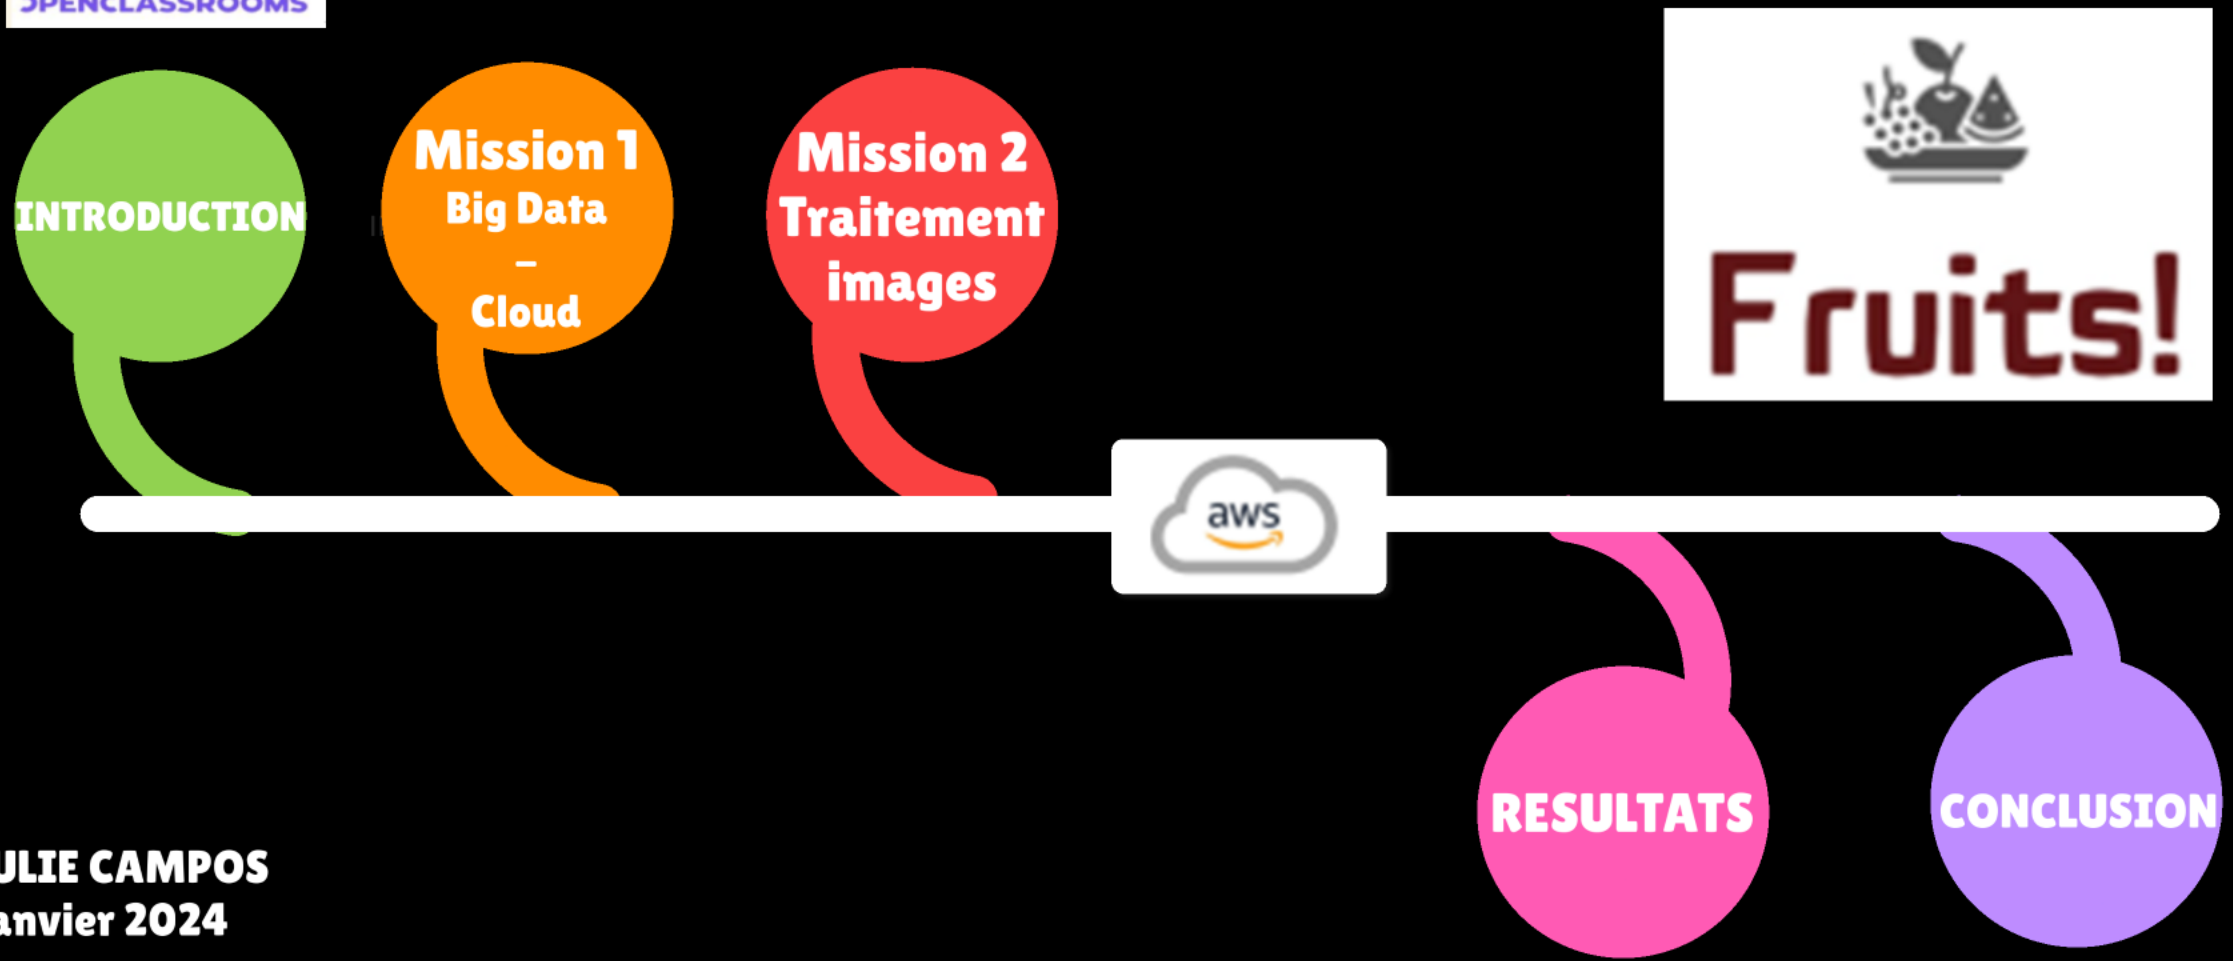
DEMONSTRATION



Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

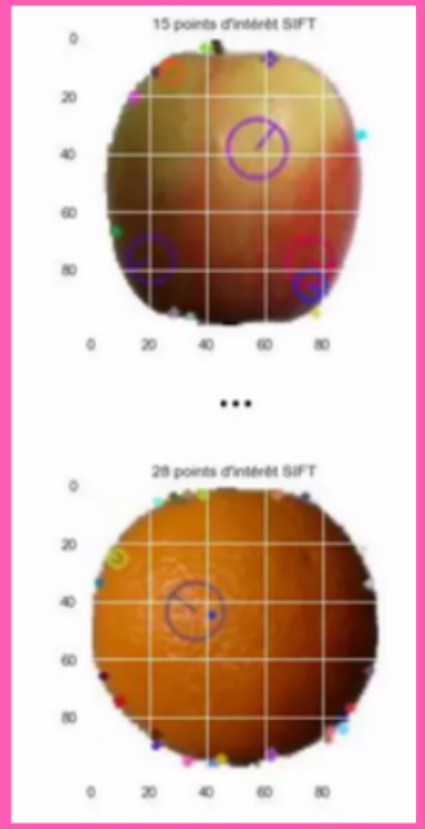
OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

RESULTATS

-> caractéristiques importantes extraites (400, 92% ACP)

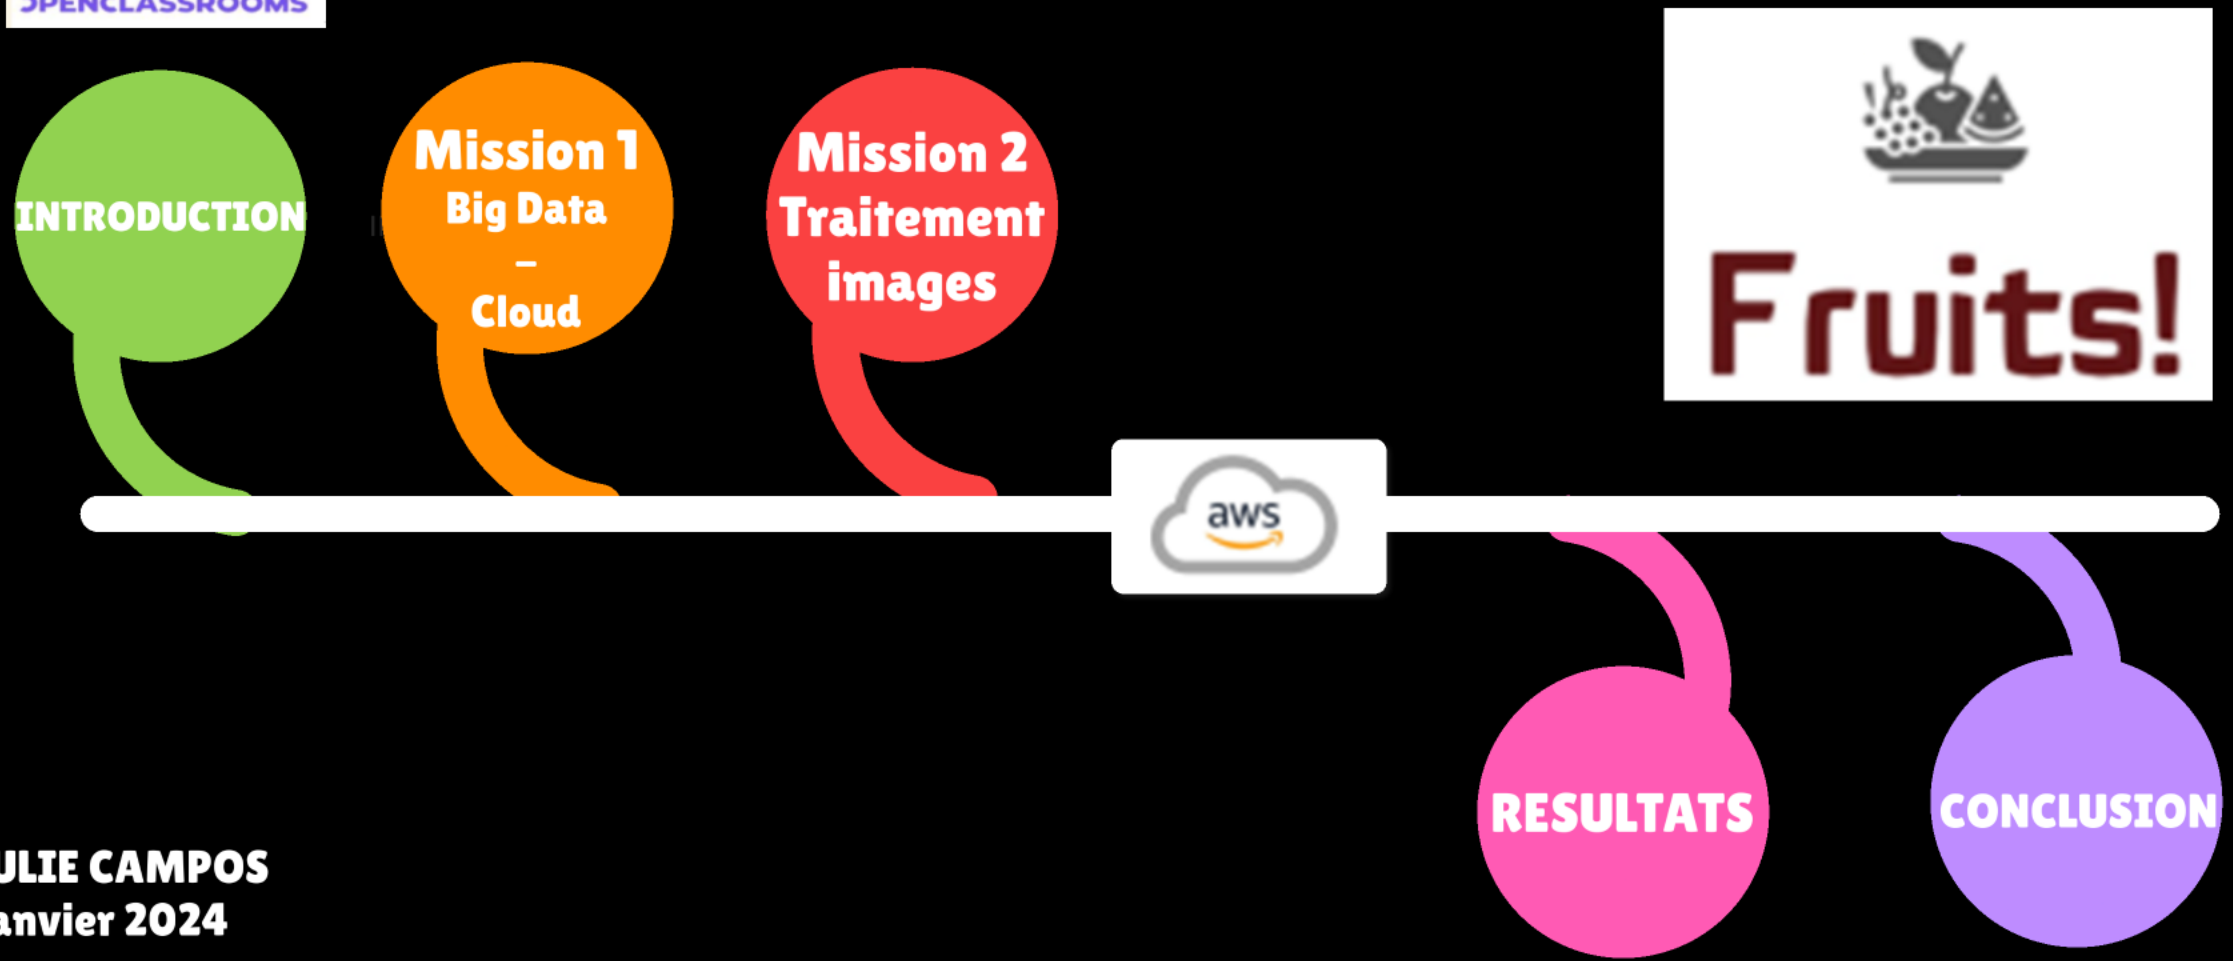


path	label	pcaFeatures
s3://oc-p8-part4/...	Pineapple Mini	[-8.6389459409195...
s3://oc-p8-part4/...	Watermelon	[-12.296506064894...
s3://oc-p8-part4/...	Watermelon	[-8.0906314435762...
s3://oc-p8-part4/...	Cucumber Ripe	[-6.7765105564183...
s3://oc-p8-part4/...	Raspberry	[-6.5021497913107...
s3://oc-p8-part4/...	Cauliflower	[-5.6660706878106...

Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024

CONCLUSION



MISSION 1 Mise en place d'une architecture Big Data sur le cloud :

- calcul distributé EMR (Elastic MapReduce)
- S3 (Simple Storage Service) pour le stockage des données : images d'origine et résultats.
- IAM (Identity & Access Management) pour la gestion des contrôles d'accès.



MISSION 2 Appropriation de la chaîne de traitement d'images : 4

- chargement des données
- preprocessing
- préparation du modèle MobileNetV2 avec transfert learning et diffusion des poids
- extraction de features
- réduction de dimensions (ACP)

L'utilisation d'un environnement Big Data offre des avantages pour "Fruits!" en termes de traitement des données, de performance, d'évolutivité et de préparation pour l'avenir

- Il sera facile de faire face à une montée de la charge des données et passer à l'échelle en redimensionnant le cluster de machines.

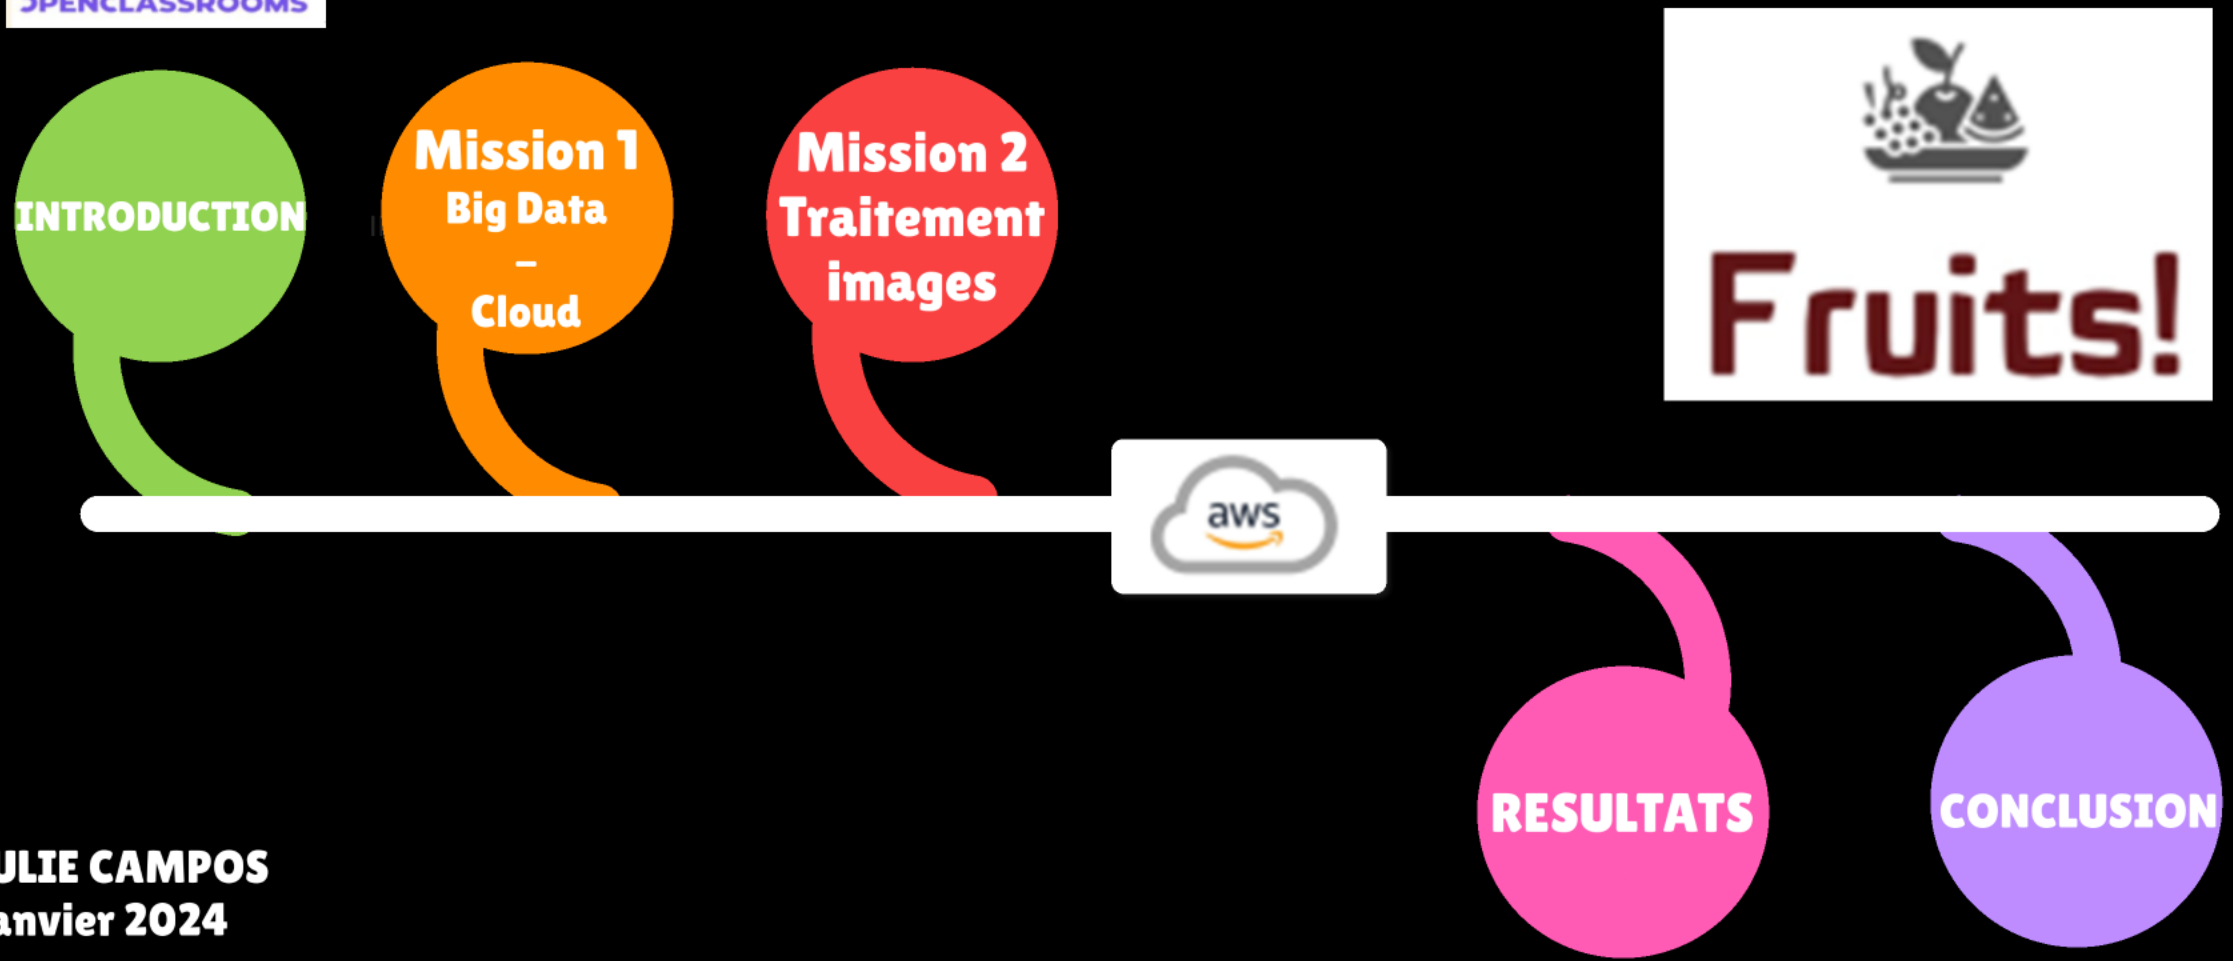
- Les coûts augmenteront en conséquence mais resteront inférieurs aux coûts engendrés par l'achat de matériels ou par la location de serveurs dédiés.

- Nous pouvons réutiliser les caractéristiques extraites pour réaliser une classification (suppervisée)

Déploiement d'un modèle dans le cloud

P8 – Parcours Data Scientist

OPENCLASSROOMS



JULIE CAMPOS
Janvier 2024